MoE 与 DeepSeekMoE 图解讲义

面向具有 Transformer 基础的读者 · 公式以 TeX 排版 · 配直观示意图 · 依据 DeepSeek-V2 论文（arXiv:2405.04434）整理

一、先回顾：Transformer 里的 FFN 是什么

你已经知道，一个 Transformer 块 = 注意力模块 + 前馈网络（FFN）。注意力负责"词与词之间交换信息"，而 FFN 负责对每个词元独立地做非线性变换——模型的很大一部分"知识"就存储在 FFN 的权重里。它的形式非常简单：

$$y = W_2\,\sigma(W_1 x)$$

其中 x 是词元的隐藏状态，σ 是激活函数，W_1、W_2 是两个大矩阵（FFN 的中间维度通常是隐藏维度的数倍）。关键问题在于：**想让模型更聪明，就要把 FFN 做大；但 FFN 越大，每个词元的计算量就同步变大**——"知识容量"和"计算成本"被死死绑在一起。

二、MoE：用"分诊制"解开这个死结

混合专家（Mixture-of-Experts，MoE）的思路是：不再只放一个巨大的 FFN，而是放 N 个较小的"专家"网络 E_1 … E_N，再加一个**路由器**（也叫门控）。每个词元进来后，路由器给它打分，只把它送到得分最高的 Top-K 个专家那里（K 通常远小于 N），最后把这几个专家的输出加权求和：

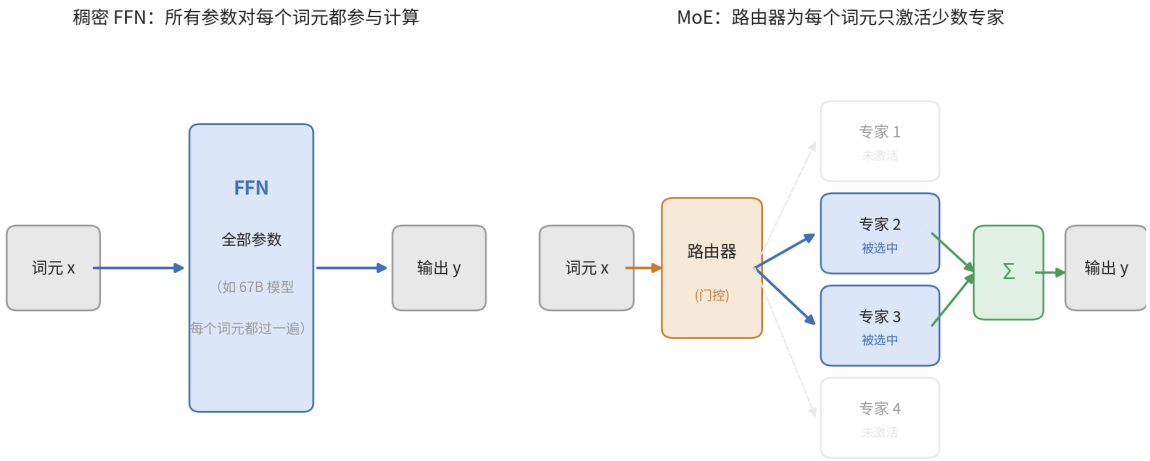


图 1 | 左：稠密 FFN，所有参数对每个词元都工作；右：MoE，路由器按词元内容选择少数专家（图中 4 选 2），未选中的专家完全不参与计算。

$$y = \sum_{i=1}^{N} g_i(x)\, E_i(x)$$

其中 E_i(x) 是第 i 个专家的输出，g_i(x) 是路由器给出的权重。路由权重由打分经过 Softmax 得到，只有进入 Top-K 的专家权重非零：

$$s_i = \mathrm{Softmax}_i\left(x^\top W_g\right), \qquad g_i(x) = s_i \ \ (i \in \mathrm{TopK}), \quad g_i(x) = 0 \ \ (\text{otherwise})$$

可以把它想象成医院：词元是病人，路由器是分诊台，专家是各科室医生。病人不需要把所有科室看一遍——分诊台判断"这是骨科问题"，就只挂骨科的号。**医院可以有很多科室（知识容量大），但每个病人只去一两个科室（计算量小）**。这就是"稀疏激活"：

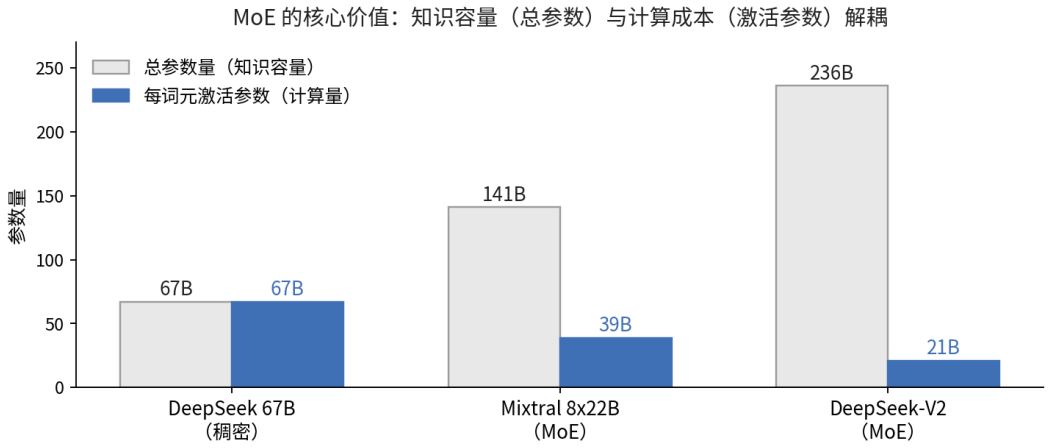


图 2 | MoE 把"知识容量"与"计算成本"解耦：DeepSeek-V2 总参数 236B（比 67B 稠密模型大得多），但每个词元只激活 21B（比 67B 少得多）。

2.1 天下没有免费的午餐：路由塌缩与负载均衡

MoE 有一个经典陷阱：如果路由器总是偏爱少数几个专家，就会出现"路由塌缩"——热门专家越来越热门（被训练得更充分、更容易再被选中），其余专家永远得不到训练，等于白占参数。为解决这个问题，训练时会额外加一项**负载均衡辅助损失**，惩罚"分配不均"：

$$\mathcal{L}_{\text{bal}} = \alpha \sum_{i=1}^{N} f_i\, P_i$$

其中 f_i 是专家 i 实际分到的词元比例，P_i 是路由器给它的平均概率，α 是控制力度的系数。两者越均衡，损失越小。

三、DeepSeekMoE：两个关键改进

DeepSeekMoE 是 DeepSeek 团队对经典 MoE（如 GShard）的改进，DeepSeek-V2 的 FFN 部分采用的就是它。它在"同样的激活参数量和总参数量"下能显著 outperform 传统 MoE，靠的是两个设计。

3.1 改进一：细粒度专家切分

传统 MoE 是"8 个大专家选 2 个"。DeepSeekMoE 把每个专家**切得更小**（中间维度减小），数量变多，同时每个词元激活的专家数也相应增多——总激活参数不变，但组合方式爆炸式增长：



图 3 | 细粒度切分示意：同样大小的专家池，切得越细、选得越多，可组合出的"专家配方"种类呈组合数级增长。

为什么组合数重要？每个小专家可以专注学习更窄、更精的知识（更高的"专家专精度"），而不同词元通过不同组合"拼配"出最适合自己的处理流水线。8 选 2 只有 28 种配方，16 选 4 就有 1820 种——DeepSeek-V2 实际是 160 选 6，配方数量是天文数字，模型的表达灵活性因此大幅提升。

3.2 改进二：共享专家

第二个观察：无论处理什么词元，总有一些知识是"人人都用得上"的（基础语法、常识等）。如果全靠路由专家，多个专家会重复学习这些通用知识，造成冗余浪费。DeepSeekMoE 的做法是：划出 N_s 个**共享专家**，**对所有词元始终激活**，专门承载通用知识；其余路由专家就可以安心钻研各自的专业领域。

3.3 完整公式与 DeepSeek-V2 的实际配置

把两个改进合起来，DeepSeek-V2 中一个 MoE 层对第 t 个词元的计算为（设该层 FFN 输入为 u_t）：

$$h'_t = u_t + \sum_{i=1}^{N_s} \mathrm{FFN}_i^{(s)}(u_t) + \sum_{i=1}^{N_r} g_{i,t}\,\mathrm{FFN}_i^{(r)}(u_t)$$

第一项 u_t 是残差连接；第二项是 N_s 个共享专家（DeepSeek-V2 中 N_s = 2，始终激活、无门控）；第三项是 N_r 个路由专家（N_r = 160）经门控加权的结果。门控值的计算与经典 MoE 一致——亲和度分数经 Softmax 后取 TopK：

$$s_{i,t} = \mathrm{Softmax}_i\left(u_t^{\top} e_i\right), \qquad g_{i,t} = s_{i,t} \ \text{if} \ s_{i,t} \in \mathrm{TopK}(\{s_{j,t}\}, K_r), \ \text{else} \ 0$$

其中 e_i 是第 i 个路由专家的"中心向量"（可学习参数，可理解为该专家的"专长画像"），u_t · e_i 衡量词元与该专家的匹配程度；K_r = 6，即每个词元激活 6 个路由专家。

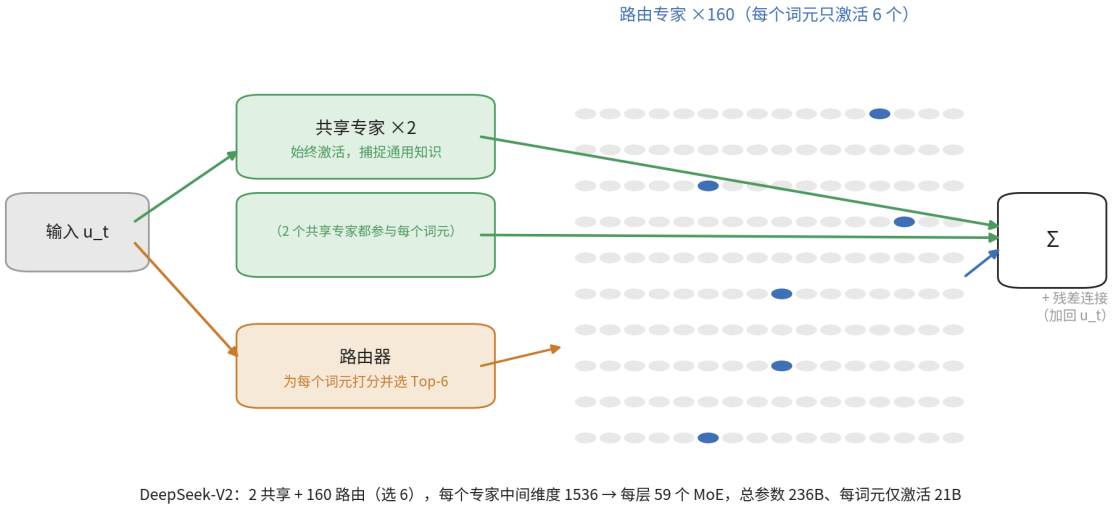


图 4 | DeepSeek-V2 的 MoE 层实际结构：2 个共享专家恒激活 + 160 个路由专家中选 6 个。除第一层外，其余 59 层的 FFN 都替换为这样的 MoE 层。

3.4 工程配套（简要）

- 设备受限路由：160 个专家分布在 8 台设备上，每个词元最多发往 3 台设备（M = 3），先把跨机通信量锁住；
- 三种均衡损失：专家级（α_1 = 0.003，防路由塌缩）、设备级（α_2 = 0.05，各设备算力均衡）、通信级（α_3 = 0.02，各设备收发均衡）；
- 词元丢弃：单台设备算力预算设为容量因子 1.0，超出部分按亲和度从低到高丢弃，但约 10% 训练序列的词元保证不丢；评估时不丢弃。

四、一页小结

概念	一句话理解	在 DeepSeek-V2 中
稠密 FFN	所有参数对每个词元都计算	仅第一层保留
MoE	N 个专家 + 路由器，每词元只算 Top-K 个	59 层 FFN 替换为 MoE
路由器（门控）	分诊台：给词元与各专家的匹配度打分	Softmax(u・e_i) 选 Top-6
负载均衡损失	防止少数专家垄断路由（路由塌缩）	专家/设备/通信三级
细粒度切分	专家切得更小更多，组合数暴涨	160 个路由专家，中间维度 1536
共享专家	通用知识集中存放，免除重复学习	2 个，始终激活
稀疏激活收益	知识容量与计算成本解耦	总 236B / 激活 21B

最终效果：与稠密的 DeepSeek 67B 相比，采用 DeepSeekMoE（配合 MLA）的 DeepSeek-V2 训练成本节省 42.5%，性能反而全面更强——这就是"以经济成本训练强大模型"的实现路径。